

Laboratório 2

Alejandro Figueiredo RA: 230532

2026-08-24

```
install.packages("remotes")
remotes::install_github("jayjacobs/ggcal")
```

As estatísticas suficientes para determinar o percentual são a quantidade total de voos e a quantidade de voos que apresentaram atraso na chegada superior a 10 minutos. Essas duas quantidades devem ser calculadas para cada dia, mês e companhia aérea. O percentual será a divisão da quantidade de voos atrasados pela quantidade total de voos.

```
getStats <- function(input, pos) {
  input %>%
    filter(
      AIRLINE %in% c("AA", "DL", "UA", "US"),
      !is.na(MONTH),
      !is.na(DAY),
      !is.na(AIRLINE),
      !is.na(ARRIVAL_DELAY)
    ) %>%
    group_by(DAY, MONTH, AIRLINE) %>%
    summarise(
      total_voos = n(),
      voos_atrasados = sum(ARRIVAL_DELAY > 10),
      .groups = "drop"
    )
}
```

O argumento pos é necessário para a leitura em partes, mas não precisa ser utilizado dentro da função.

```

colunas <- cols_only(
  MONTH = col_integer(),
  DAY = col_integer(),
  AIRLINE = col_character(),
  ARRIVAL_DELAY = col_double()
)

stats_lotes <- read_csv_chunked(
  "flights.csv.zip",
  callback = DataFrameCallback$new(getStats),
  chunk_size = 100000,
  col_types = colunas
)

head(stats_lotes)

```

```

# A tibble: 6 x 5
  DAY MONTH AIRLINE total_voos voos_atrasados
  <int> <int> <chr>      <int>      <int>
1     1     1    AA        1379        514
2     1     1    DL        1558        132
3     1     1    UA        1269        367
4     1     1    US        1028        201
5     2     1    AA        1508        649
6     2     1    DL        2261        406

```

O objeto `stats_lotes` possui as estatísticas calculadas em cada parte da base. Como um mesmo dia pode aparecer em partes diferentes, precisamos somar os resultados antes de calcular o percentual final.

```

computeStats <- function(dados) {
  dados %>%
    group_by(DAY, MONTH, AIRLINE) %>%
    summarise(
      total_voos = sum(total_voos),
      voos_atrasados = sum(voos_atrasados),
      .groups = "drop"
    ) %>%
    transmute(
      Cia = AIRLINE,
      Data = as.Date(paste(2015, MONTH, DAY, sep = "-")),

```

```

    Perc = voos_atrasados / total_voos
  ) %>%
  arrange(Cia, Data)
}

stats <- computeStats(stats_lotes)

head(stats)

```

```

# A tibble: 6 x 3
  Cia   Data      Perc
  <chr> <date>    <dbl>
1 AA    2015-01-01 0.373
2 AA    2015-01-02 0.430
3 AA    2015-01-03 0.538
4 AA    2015-01-04 0.602
5 AA    2015-01-05 0.491
6 AA    2015-01-06 0.366

```

```

pal <- scale_fill_gradient(
  low = "#4575b4",
  high = "#d73027"
)

```

```

baseCalendario <- function(stats, cia) {
  dados_cia <- stats %>%
    filter(Cia == cia) %>%
    select(Data, Perc)

  ggcal(dados_cia$Data, dados_cia$Perc) +
    theme(strip.placement = "outside")
}

```

```

cAA <- baseCalendario(stats, "AA")
cDL <- baseCalendario(stats, "DL")
cUA <- baseCalendario(stats, "UA")
cUS <- baseCalendario(stats, "US")


```

```

cAA + pal + ggtitle("Percentual de atrasos da companhia AA")


```

Percentual de atrasos da companhia AA




```
cDL + pal + ggtitle("Percentual de atrasos da companhia DL")
```

Percentual de atrasos da companhia DL




```
cUA + pal + ggtitle("Percentual de atrasos da companhia UA")
```

Percentual de atrasos da companhia UA



```
cUS + pal + ggtitle("Percentual de atrasos da companhia US")
```

Percentual de atrasos da companhia US



```

Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()

```

```

[1] "2026-08-24 23:56:09 -03"

```