

Laboratório 3

Alejandro Figueiredo RA: 230532

2026-09-01

```
install.packages(c("tidyverse", "leaflet", "webshot2"))
```

As estatísticas suficientes para determinar o atraso médio são a soma dos atrasos e a quantidade de voos para cada aeroporto de destino. Primeiro, essas duas quantidades são calculadas em cada parte da base. Depois, os resultados das partes são somados para calcular a média final.

```
getStats <- function(input, pos) {  
  input %>%  
    filter(!startsWith(DESTINATION_AIRPORT, "1")) %>%  
    drop_na() %>%  
    group_by(DESTINATION_AIRPORT) %>%  
    summarise(  
      soma_atrasos = sum(ARRIVAL_DELAY),  
      total_voos = n(),  
      .groups = "drop"  
    )  
}
```

O argumento pos é necessário para a leitura em partes, mas não precisa ser utilizado dentro da função.

```
computeStats <- function(input) {  
  input %>%  
    group_by(DESTINATION_AIRPORT) %>%  
    summarise(  
      MEAN_DELAY = sum(soma_atrasos) / sum(total_voos),  
      .groups = "drop"  
    )  
}
```

```

colunas_voos <- cols_only(
  DESTINATION_AIRPORT = col_character(),
  ARRIVAL_DELAY = col_double()
)

flights <- read_csv_chunked(
  "flights.csv.zip",
  callback = DataframeCallback$new(getStats),
  chunk_size = 1000000,
  col_types = colunas_voos
)

flights <- computeStats(flights)

head(flights)

```

```

# A tibble: 6 x 2
  DESTINATION_AIRPORT MEAN_DELAY
  <chr>              <dbl>
1 ABE                5.80
2 ABI                4.08
3 ABQ                5.61
4 ABR               -3.39
5 ABY                8.68
6 ACK                4.91

```

```

airlines <- read_csv(
  "airlines.csv",
  show_col_types = FALSE
)

head(airlines)

```

```

# A tibble: 6 x 2
  IATA_CODE AIRLINE
  <chr>      <chr>
1 UA        United Air Lines Inc.
2 AA        American Airlines Inc.
3 US        US Airways Inc.
4 F9        Frontier Airlines Inc.
5 B6        JetBlue Airways
6 00        Skywest Airlines Inc.

```

```

colunas_aeroportos <- cols_only(
  IATA_CODE = col_character(),
  CITY = col_character(),
  STATE = col_character(),
  LATITUDE = col_double(),
  LONGITUDE = col_double()
)

airports <- read_csv(
  "airports.csv",
  col_types = colunas_aeroportos
)

head(airports)

```

```

# A tibble: 6 x 5
  IATA_CODE CITY      STATE LATITUDE LONGITUDE
<chr>      <chr>      <chr>   <dbl>   <dbl>
1 ABE      Allentown    PA      40.7    -75.4
2 ABI      Abilene      TX      32.4    -99.7
3 ABQ      Albuquerque NM      35.0    -107.
4 ABR      Aberdeen    SD      45.4    -98.4
5 ABY      Albany      GA      31.5    -84.2
6 ACK      Nantucket    MA      41.3    -70.1

```

A chave da tabela flights é DESTINATION_AIRPORT e a chave da tabela airports é IATA_CODE. Para encontrar os aeroportos presentes em flights e ausentes em airports, utilizamos anti_join.

```

aeroportos_ausentes <- flights %>%
  anti_join(
    airports,
    by = c("DESTINATION_AIRPORT" = "IATA_CODE")
  )

aeroportos_ausentes

```

```

# A tibble: 0 x 2
# i 2 variables: DESTINATION_AIRPORT <chr>, MEAN_DELAY <dbl>

```

O resultado possui zero linhas, então todos os aeroportos presentes em flights também estão presentes em airports.

O `left_join` é apropriado porque mantém todos os aeroportos da tabela flights e adiciona as informações correspondentes da tabela airports. As chaves são indicadas explicitamente no argumento `by`.

```
flights <- flights %>%  
  left_join(  
    airports,  
    by = c("DESTINATION_AIRPORT" = "IATA_CODE")  
  )  
  
head(flights)
```

```
# A tibble: 6 x 6  
  DESTINATION_AIRPORT MEAN_DELAY CITY      STATE LATITUDE LONGITUDE  
  <chr>               <dbl> <chr>    <chr>    <dbl>    <dbl>  
1 ABE                 5.80 Allentown PA       40.7     -75.4  
2 ABI                 4.08 Abilene   TX       32.4     -99.7  
3 ABQ                 5.61 Albuquerque NM       35.0    -107.  
4 ABR                -3.39 Aberdeen SD       45.4     -98.4  
5 ABY                 8.68 Albany   GA       31.5     -84.2  
6 ACK                 4.91 Nantucket MA       41.3     -70.1
```

```
aeroportos_estado <- flights %>%  
  group_by(STATE) %>%  
  summarise(  
    numero_aeroportos = n(),  
    .groups = "drop"  
  ) %>%  
  arrange(desc(numero_aeroportos))  
  
aeroportos_estado
```

```
# A tibble: 54 x 2  
  STATE numero_aeroportos  
  <chr>         <int>  
1 TX             24  
2 CA             22  
3 AK             19  
4 FL             17
```

```

5 MI 15
6 NY 14
7 CO 10
8 MN 8
9 MT 8
10 NC 8
# i 44 more rows

```

Para representar os atrasos no mapa, cada marcador mostra o código do aeroporto, a cidade, o estado e o atraso médio observado.


```

dados_mapa <- flights %>%
  drop_na(LATITUDE, LONGITUDE)

this <- leaflet(dados_mapa) %>%
  addTiles() %>%
  addMarkers(
    lng = ~LONGITUDE,
    lat = ~LATITUDE,
    label = ~DESTINATION_AIRPORT,
    popup = ~paste(
      "Aeroporto:", DESTINATION_AIRPORT, "<br>",
      "Cidade:", CITY, "-", STATE, "<br>",
      "Atraso médio:", round(MEAN_DELAY, 2), "minutos"
    ),
    clusterOptions = markerClusterOptions()
  )

this

```



```
Sys.setenv(TZ = "America/Sao_Paulo")  
Sys.time()
```

```
[1] "2026-08-31 22:18:33 -03"
```